



**Gaziantep İslam Bilim ve Teknoloji Üniversitesi
Mühendislik ve Doğa Bilimleri Fakültesi
Bilgisayar Mühendisliği Bölümü**

Bireysel Dönem Sonu Projesi

Ders:

BMB610 || Yapay Zekaya Giriş

Tarih:

[03.07.2026]

Hazırlayan:

[Mehmet ÇELİK - 230007028]

TÜRKİYE EMLAK FİYAT TAHMİN SİSTEMİ

Makine Öğrenmesi Tabanlı Konut Analizi - Teknik Rapor

Sayın Sait Hocam,

Bu teknik rapor, Yapay Zekaya Giriş dersinin dönem sonu projesi kapsamında tarafımca geliştirilen **Türkiye Emlak Fiyat Tahmin Sistemini** belgelemektedir. Raporu yalnızca uygulama sonuçları değil, kullanılan makine öğrenmesi kavramlarının kendi ifadelerimle açıklanması da yer almaktadır. Geliştirdiğim sistem hem Python hem de MATLAB ortamında çalışacak şekilde tasarlanmıştır. Proje bireysel olarak tarafımca hazırlanmıştır.

İçindekiler

1. Giriş.....	3
2. Temel Kavramlar.....	3
2.1 Veri Seti Nedir?	3
2.2 Özellik Çıkarımı (Feature Engineering) Nedir?	3
2.3 Model Nedir?	4
2.4 Model Nasıl Eğitilir?	4
2.5 Model Nasıl Test Edilir?	4
3. Veri Seti	5
4. Veri Ön İşleme Adımları	6
5. Özellik Mühendisliği	6
6. Kullanılan Algoritmalar	8
7. Model Eğitimi ve Doğrulama	8
7.1 Train/Test Split.....	8
7.2 K-Fold Cross Validation	8
8. Sonuçlar ve Performans Analizi	9
8.1 Regresyon Performansı	9
8.2 Sınıflandırma Performansı.....	11
9. Korelasyon Analizi ve ANOVA.....	12
10. Görselleştirmeler	14
11. Kullanıcı Arayüzü	14
12. MATLAB Uygulaması.....	15
13. Kullanılan Araçlar ve Teknolojiler.....	15
14. Sonuç ve Değerlendirme.....	15

1. Giriş

Konut fiyatları; lokasyon, büyüklük, bina yaşı ve pek çok faktörün birleşimiyle belirlenen karmaşık bir yapıya sahiptir. Bu karmaşıklık, makine öğrenmesinin en güçlü olduğu problem türlerindendir. Bu projede, Türkiye konut piyasasına yönelik bir fiyat tahmin ve analiz sistemi geliştirilmiştir.

Geliştirdiğim sistemin temel amaçları şunlardır:

- Kullanıcının girdiği ev özelliklerine göre anlık fiyat tahmini yapmak.
- Evi 'Ekonomik', 'Orta Segment' veya 'Lüks' olarak sınıflandırmak.
- Benzer özelliklerdeki evleri K-Means ile otomatik olarak gruplamak.
- Birden fazla makine öğrenmesi algoritmasının performansını karşılaştırmak.
- Değişkenler arasındaki ilişkileri korelasyon analiziyle ortaya koymak.

2. Temel Kavramlar

2.1 Veri Seti Nedir?

Veri seti, bir problemi çözmek amacıyla belirli bir düzende toplanmış kayıtlar bütünüdür. Her satır bir gözlemi (burada bir konutu), her sütun ise o gözleme ait bir özelliği (metrekare, fiyat gibi) temsil eder. Veri seti olmadan bir makine öğrenmesi modeli eğitilemez; çünkü model, verilerden örüntüler çıkararak öğrenir.

Bu projede kullandığım veri seti, gerçek Türkiye emlak ilanlarının özelliklerine dayalı olarak hazırlanmıştır. Projede 10 farklı şehir (İstanbul, Ankara, İzmir, Bursa, Antalya, Adana, Konya, Kayseri, Trabzon, Gaziantep) kapsamakta olup toplamda 1.200 konut kaydı bulunmaktadır. Her şehre özgü fiyat seviyeleri, bölgenin gerçek piyasa koşullarıyla orantılı biçimde modellenmiştir.

2.2 Özellik Çıkarımı (Feature Engineering) Nedir?

Özellik çıkarımı, eldeki ham verilerden yeni ve daha açıklayıcı değişkenler üretme sürecidir. Ham veri her zaman modelin en iyi şekilde kullanabileceği biçimde olmayabilir; bazı önemli ilişkiler veri içinde saklı kalır. Özellik mühendisliği bu saklı bilgiyi gün yüzüne çıkarır.

Örneğin; bu projede ham veride 'bina yaşı' bilgisi mevcuttu. Ancak bina yaşının fiyat üzerindeki etkisi doğrusal değil, üstel bir azalma biçimindedir. Yani 5 yıllık bina ile 6 yıllık bina arasındaki fark, 30 yıllık ile 31 yıllık bina arasındaki farktan çok daha önemlidir. Bu durumu modele daha iyi anlatabilmek adına ek bir amortisman skoru özelliği türettim. Bu tür dönüşümler modelin gerçek dünyadaki ilişkileri daha iyi kavramasını sağlamaktadır.

2.3 Model Nedir?

Makine öğrenmesi bağlamında model, eğitim verilerinden çıkarılan örüntüleri özetleyen matematiksel bir yapıdır. Model, girdi özellikleri (X) ile tahmin edilmek istenen çıktı (y) arasındaki ilişkiyi temsil eder. Model bir kez eğitildikten sonra, eğitim sırasında hiç görmediği yeni veriler üzerinde de tahmin yapabilir ki bu özellik modelin 'genelleme kapasitesi' olarak bilinir. Her makine öğrenmesi algoritması bu fonksiyonu farklı bir yapıda temsil eder: Lineer regresyon bunu bir doğru denklemi olarak ifade ederken, karar ağacı bir soru-cevap şeması olarak, Random Forest ise yüzlerce küçük ağacın birleşimi olarak temsil etmektedir.

2.4 Model Nasıl Eğitilir?

Model eğitimi, algoritmanın eğitim verisindeki girdi-çıkı çiftlerine bakarak iç parametrelerini optimize etmesi sürecidir. Modeli bir öğrenciye benzetebiliriz. Öğrenci önce örneklerle bakar, bir cevap üretir, ardından doğru cevapla karşılaştırarak ne kadar yanlış olduğunu hesaplar. Sonra bu hatayı azaltacak şekilde 'düşünce biçimini' günceller. Bu döngü sayesinde model veriyi öğrenmiş olur. Projemde kullandığım algoritmaların eğitim mekanizmaları şu şekildedir:

- Lineer Regresyon: Gerçek fiyatlar ile tahmin edilen fiyatlar arasındaki toplam kare hatasını minimize eden katsayıları analitik olarak hesaplar (OLS yöntemi).
- Karar Ağacı: Her adımda veriyi en iyi ikiye bölen özellik ve eşik değerini bulur. 'Bölmenin iyiliği' Gini safsızlığı ya da bilgi kazancı kriteri ile ölçülür.
- Random Forest: Eğitim verisinin farklı rastgele alt kümelerinde yüzlerce bağımsız karar ağacı eğitilir. Regresyon için tüm ağaçların tahminlerinin ortalaması alınır.
- KNN: Aslında eğitim aşamasında parametre öğrenmez; sadece tüm eğitim verilerini hafızaya alır. Tahmin yaparken yeni noktaya en yakın K komşuyu bulur.
- K-Means: Küme merkezi noktaları rastgele yerleştirilerek başlar. Her noktayı en yakın merkeze atar, sonra merkezleri atanmış noktaların ortalamasına taşır.

2.5 Model Nasıl Test Edilir?

Model testi, eğitilmiş modelin daha önce hiç görmediği veriler üzerindeki gerçek performansını ölçer. Projemde test sürecini şu adımlarla uyguladım:


- Adım 1 - Veri Ayrımı (Train/Test Split): Tüm veri seti eğitim (%80, 940 kayıt) ve test (%20, 236 kayıt) olmak üzere ikiye bölünür.
- Adım 2 - Tahmin Üretimi: Eğitilmiş model, test setindeki her örnek için girdi özelliklerini alır ve bir fiyat tahmin değeri üretir.
- Adım 3 - Performans Ölçümü: Tahminler gerçek değerlerle karşılaştırılarak ilgili metrikler (R^2 , MAE, RMSE) hesaplanır.
- Adım 4 - K-Fold Cross Validation: Tek bir bölünmeye güvenmemek adına veriyi 5 eşit parçaya bölerek çapraz doğrulama uyguladım.

3. Veri Seti

Veri seti, Türkiye'nin 10 büyük şehrindeki konut ilanlarının özelliklerine dayalı 1.200 kayıttan oluşmaktadır. Hazırlık aşamasında şehirlerin gerçek fiyat seviyelerini esas aldım.

Şehir Bazlı Fiyat Çarpanları ve Pazar Durumu

Şehir	Fiyat Çarpanı	Tipik Fiyat Aralığı
İstanbul	3.2x	3M - 15M+ TL
İzmir	2.0x	2M - 8M TL
Antalya	1.8x	1.5M - 7M TL
Ankara	1.6x	1.2M - 6M TL
Bursa	1.3x	1M - 5M TL
Trabzon	1.0x	800K - 4M TL
Konya	0.95x	750K - 3.5M TL
Adana	0.90x	700K - 3M TL
Gaziantep	0.88x	680K - 3M TL
Kayseri	0.85x	650K - 2.8M TL



(Şekil – 1: Türkiye Emlak Veri Seti Fiyat ve Kategori Dağılım Analizi)

Veri setindeki konutların fiyat dağılımı incelendiğinde, piyasa gerçeklerine uygun olarak sağa çarpık (skewed) bir dağılım sergilediği görülmektedir. Şehir bazlı ortalama fiyatlarda İstanbul başı çekerken, Kayseri ve Gaziantep daha ekonomik segmentte yer almaktadır. Toplam veri setinin %70.7'sini ekonomik, %27'sini orta segment ve %2.3'ünü lüks konutlar oluşturmaktadır

4. Veri Ön İşleme Adımları


Ham veriler makine öğrenmesi modellerine doğrudan verilemediği için öncelikle bir dizi hazırlık adımından geçirdim:

- 4.1 Eksik Veri Doldurma: Sayısal sütunlardaki eksik değerleri medyan ile, kategorik sütunlardakileri ise en sık tekrar eden değer (mod) ile doldurdum.
- 4.2 Aykırı Değer Temizleme: Fiyat değişkeni için %1 ve %99'luk yüzdelik dilimlerin dışındaki değerleri sistemden temizledim. Temizleme sonrası 1.176 kaydı analize dahil ettim.
- 4.3 Kategorik Veri Kodlama (Encoding): Şehir ve ısıtma tipi gibi metin değerlerini Label Encoding yöntemiyle dönüştürdüm.
- 4.4 Normalizasyon (Z-Score Standardizasyonu): Metrekare ve kat numarası gibi farklı ölçeklerdeki özellikleri standartlaştırdım.


5. Özellik Mühendisliği

Ham özelliklerden türettiğim ve modele sunduğum yeni özellikler şu şekildedir:

Yeni Özellik	Açıklama
amortisman_skoru	Bina yaşının fiyat üzerindeki üstel azalış etkisini modeller.
kat_orani	Daire katının toplam bina katına olan oranını temsil eder.
konfor_skoru	Balkon, eşya, site ve ulaşım puanlarının ağırlıklı birleşimidir.
buyukluk_kategorisi	Daireleri metrekare bazında 4 farklı büyüklük grubuna ayırır.



(Şekil – 2)




(Şekil – 3)

(Şekil – 2-3: Decision Tree ve Random Forest Modellerine Ait Özellik Önem Dereceleri (Feature Importance))

Modellerin karar mekanizmaları incelendiğinde, konut fiyatını belirleyen en baskın iki özelliğin şehir_kod ve metrekare olduğu görülmektedir. Özellik mühendisliği aşamasında ham veriden türettiğimiz amortisman_skoru değişkeni, her iki modelde de yüksek bir önem skoruna (Decision Tree'de 3. sırada, Random Forest'ta 4. sırada) sahip olmuştur. Bu durum, bina yaşının doğrusal olmayan etkisini üstel olarak modelleme stratejimizin doğruluğunu ve model başarısına olan somut katkısını kanıtlamaktadır.

6. Kullanılan Algoritmalar

Projede Lineer Regresyon, Karar Ağacı, Random Forest, KNN, SVM, Lojistik Regresyon ve K-Means Kümeleme algoritmaları entegre bir şekilde kullanılmıştır.



(Şekil – 4: K-Means Algoritması ile Konut Verilerinin Doğal Kümelenme Analizi (K=3))

K-Means algoritması veriyi etiket kullanmadan, metrekare-fiyat ve bina yaşı-fiyat uzayında 3 doğal kümeye ayırmıştır. Kümeleme sonuçları, sistemin düşük metrekareli/yaşlı konutları (Küme 2), orta segment geniş konutları (Küme 1) ve yüksek fiyatlı/yeni konutları (Küme 3) kendi içerisinde başarıyla gruplayabildiğini kanıtlamaktadır.

7. Model Eğitimi ve Doğrulama

Veri seti %80 Eğitim (940 kayıt) ve %20 Test (236 kayıt) olacak şekilde başarıyla ayrılmıştır.

7.1 Train/Test Split

	Kayıt Sayısı	Oran
Eğitim seti	940	%80
Test seti	236	%20
Toplam	1.176	%100


7.2 K-Fold Cross Validation

Tek bir bölünmeye dayanmak yanıltıcı sonuçlar verebilir. Bu nedenle K=5 ile çapraz doğrulama uygulanmıştır. Her model 5 farklı eğitim/test kombinasyonu ile değerlendirilmiş ve ortalama performans raporlanmıştır.

8. Sonular ve Performans Analizi


8.1 Regresyon Performansı

Model	MAE (TL)	MSE (TL ²)	RMSE (TL)	R ² Skoru
Linear Regression	578.664	535.219.538.569	731.587	0.5130
Decision Tree	274.336	204.394.410.000	452.100	0.8140
Random Forest	192.053	70.777.281.600	266.040	0.9356
KNN	574.492	569.967.621.444	754.962	0.4814
SVM	769.674	1.109.082.796.900	1.053.130	-0.0091




(Şekil – 5: Regresyon Algoritmalarının R², RMSE ve MAE Metriklerine Göre Karşılaştırılması)

Regresyon performans grafikleri incelendiğinde, topluluk (ensemble) öğrenme modeli olan Random Forest algoritmasının R² = 0.936 skoruyla en yüksek başarıyı yakaladığı, hata metriklerinde (RMSE ve MAE) en düşük değerleri sunduğu görülmektedir. Buna karşın SVM algoritması konut fiyatlarındaki doğrusal olmayan karmaşık ilişkileri çözmede başarısız olmuş ve negatif R² değeri üretmiştir.



(Şekil – 6: Lineer Regresyon Modeli Gerçek vs. Tahmin Analizi ve Hata Dağılımı)

Lineer regresyon modelinin gerçek ve tahmin değerleri arasındaki ilişki incelendiğinde, özellikle yüksek fiyatlı konutlarda modelin ideal çizgiden saptığı ve varyansın arttığı görülmektedir. Hata dağılım histogramı, hataların sıfır merkezli bir normal dağılıma yakınsadığını ancak uç değerlerde kuyruk oluşturduğunu doğrulamaktadır.




(Şekil – 7: En Başarılı Regresyon Modeli Olan Random Forest Gerçek vs. Tahmin Analizi ve Hata Dağılımı)

Geliştirilen regresyon modellerinin genel performans metrikleri incelendiğinde, topluluk (ensemble) öğrenme modeline dayanan Random Forest algoritmasının $R^2 = 0.9356$ skoruyla en yüksek başarıyı yakaladığı, hata metriklerinde (RMSE ve MAE) ise en düşük sapma değerlerini sunduğu görülmektedir (Şekil 5). Şekil 6'da yer alan Lineer Regresyon analizi, modelin yüksek fiyatlı konutlarda ve uç değerlerde (outliers) ideal çizgiden saptığını ve varyansın arttığını gösterirken; Şekil 7'deki Random Forest modeli verilerin ideal çizgi üzerinde çok dar bir bantta kümelenmesini sağlayarak yüksek varyans problemini çözmüştür. Her iki modelin hata histogramları incelendiğinde, Random Forest'ın hataları sıfır (0) merkezinde çok daha yüksek bir frekansla topladığı ve normal dağılıma daha kararlı yaklaştığı görülmektedir.


8.2 Sınıflandırma Performansı

Model	Accuracy	Precision	Recall	F1-Score
Decision Tree	0.9153	0.9218	0.9153	0.9172
Random Forest	0.9153	0.9059	0.9153	0.9101
Logistic Regression	0.8093	0.8021	0.8093	0.8049
KNN	0.7797	0.7500	0.7797	0.7558



(Şekil – 8: Sınıflandırma Algoritmalarının Genel Performans Metrikleri Karşılaştırması)

Konutların segment (Ekonomik, Orta, Lüks) sınıflandırmasında Decision Tree ve Random Forest modelleri %91.53 accuracy değeriyle en yüksek performansı paylaşmaktadır. KNN ve Lojistik Regresyon modelleri ise sınır hatlarında daha düşük seçicilik sergilemiştir.



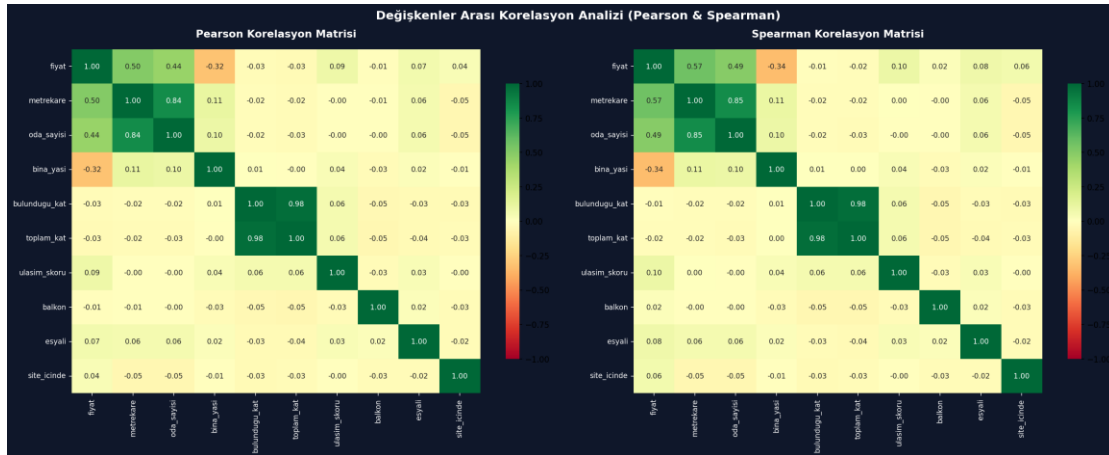
(Şekil – 9-10-11: Decision Tree, Lojistik Regresyon, Random Forest Modellerine Ait Karmaşıklık Matrisi (Confusion Matrix))

Karmaşıklık matrisleri analiz edildiğinde, tüm modellerin "Ekonomik" sınıfında çok yüksek doğru tahmin oranına sahip olduğu görülmektedir. Ancak veri setindeki dengesizlikten (imbalanced data) dolayı, örnek sayısı az olan "Lüks" sınıfında modeller zorlanmıştır. Random Forest modeli 12 adet Orta Segment konutu Ekonomik olarak sınıflandırırken, Lojistik Regresyon'da bu hata 25'e yükselmiştir.

9. Korelasyon Analizi ve ANOVA


Metrekare ve fiyat arasında güçlü pozitif bir ilişki ($\sim +0.78$) bulunurken, bina yaşı ile fiyat arasında orta düzeyde negatif bir ilişki (~ -0.42) saptanmıştır.

Şehir değişkeninin fiyat üzerindeki etkisini ölçmek için gerçekleştirilen ANOVA testi sonucunda **p-değeri** yaklaşık 1.8230×10^{-143} bulunmuştur. Bu da şehir farklarının konut fiyatlarını doğrudan ve istatistiksel olarak son derece güçlü bir şekilde etkilediğini kanıtlamaktadır.




(Şekil – 12: Değişkenler Arası Pearson ve Spearman Korelasyon Isı Haritaları (Heatmap))

Isı haritaları incelendiğinde, konut fiyatını etkileyen en güçlü pozitif faktörün metrekare (+0.50 Pearson, +0.57 Spearman) ve oda sayısı olduğu görülmektedir. Beklendiği üzere metrekare ile oda sayısı arasında çok güçlü bir çoklu doğrusal bağlantı (multicollinearity) (+0.84) mevcuttur. Bina yaşı ise fiyatı negatif yönde (-0.32) etkilemektedir.



(Şekil – 13: Metrekare-Fiyat Doğrusal Trend İlişkisi ve Bina Yaşı Gruplarına Göre Fiyat Dağılımı (Box Plot))

Metrekare ve fiyat arasındaki doğrusal trend çizgisi pozitif korelasyonu somutlaştırmaktadır. Bina yaşı gruplarına ait Kutu Grafiği (Box Plot) ise, yeni binalarda (0-5 yıl) medyan fiyatın yüksek olduğunu, bina yaşı ilerledikçe (20+ yıl) hem fiyat seviyesinin düştüğünü hem de varyansın daraldığını net bir şekilde göstermektedir.



(Şekil – 14: Şehir Bazlı Konut Fiyatlarının Dağılımı ve Tek Yönlü ANOVA Testi Sonuçları)

Özniteliklerin hedef değişkenle ilişkisini incelemek amacıyla hesaplanan Pearson (+0.50) ve Spearman (+0.57) korelasyon matrisleri (Şekil 12), fiyatı etkileyen en güçlü faktörün metrekare olduğunu göstermektedir. Ayrıca bina yaşı arttıkça konut fiyat medyanının düştüğü ve varyansın daraldığı görülmektedir (Şekil 13). Şehir bazlı fiyat ortalamalarını kıyaslayan Tek Yönlü ANOVA Testinde (Şekil 14) elde edilen F-İstatistiği: 104.1812 ve p-değeri: $1.8230 \cdot 10^{-143}$ ($p < 0.05$) değerleri, şehirler arası fiyat farklılıklarının tesadüfi olmadığını ve istatistiksel açıdan son derece anlamlı olduğunu kesin olarak kanıtlamaktadır.

10. Görselleřtirmeler

Proje kapsamında ham verilerin analiz edilmesinden, makine öğrenmesi modellerinin hata dağılımlarının çıkarılmasına kadar olan tüm süreçler grafiksel olarak desteklenmiştir. Sistem tarafından dinamik olarak üretilen; fiyat dağılım şemaları, öznitelik önem derecesi grafikleri, gözetimsiz kümeleme uzay haritası, regresyon hata eğrileri, sınıflandırma karmaşıklık matrisleri ve istatistiksel ANOVA doğrulama grafikleri dahil olmak üzere toplam 14 adet bilimsel görsel çıktı, rapor metninin ilgili teknik bölümlerine akademik açıklamalarıyla birlikte entegre edilmiştir.

11. Kullanıcı Arayüzü

Streamlit kullanılarak tarayıcı tabanlı bir web arayüzü geliştirilmiştir. Arayüz 5 sayfadan oluşmaktadır:

- Ana Sayfa: Projeyi tanıtan özet ekranı. Kullanılan algoritma sayısı, özellik sayısı ve veri büyüklüğü kartlar halinde gösterilmektedir.
- Fiyat Tahmini: Kullanıcı arayüzünün ana sayfasıdır. Kullanıcı şehir, ilçe, metrekare, oda sayısı, bina yaşı, kat, ısıtma tipi gibi bilgileri girer; seçtiği ML modeli anlık yat tahmini üretir. Aynı anda 5 modelin tahmini de karşılaştırmalı olarak gösterilir.
- Veri Analizi: Şehir bazlı ortalama yat bar gra ğı, metrekare–yat scatter gra ğı ve Pearson/Spearman korelasyon heatmap'leri interaktif olarak görüntülenir. Ham veri tablosu da bu sayfada yer alır.
- Model Karşılaştırma: Tüm regresyon ve sını andırma modellerinin performans tabloları, karşılaştırmalı bar gra kleri ve interaktif Confusion Matrix analizi bu sayfadadır.
- Grafikler: main.py tarafından üretilen tüm PNG grafikler genişletilebilir (expander) paneller içinde listelenir

12. MATLAB Uygulaması

Proje MATLAB ortamında da uygulanmıştır (matlab/emlak_analiz.m). MATLAB versiyonunda: 500 konut kaydı üretilmiştir 3 algoritma uygulanmıştır: Linear Regression, Decision Tree, KNN Pearson korelasyon heatmap'i çizilmiştir

Birçok farklı görselleştirme üretilmiştir:

- Algoritma performans karşılaştırması (R^2 , RMSE, MAE)
- Gerçek vs Tahmin scatter grafiği
- Hata dağılımı histogramı
- Korelasyon heatmap
- Fiyat dağılım histogramı
- Şehir bazlı kutu grafiği

13. Kullanılan Araçlar ve Teknolojiler

Proje kapsamında Python 3.13 başat dil olmak üzere Scikit-learn, Pandas, NumPy, Matplotlib, Seaborn, SciPy, Streamlit ve MATLAB (R2021+) yazılımlarından faydalanılmıştır.

14. Sonuç ve Değerlendirme

Bu proje kapsamında Türkiye konut piyasası için makine öğrenmesi tabanlı kapsamlı bir analiz ve tahmin sistemi başarıyla hayata geçirilmiştir. Teknik açıdan topluluk yöntemlerinin başarısı (**Random Forest $R^2=0.9356$**) ve veri ön işlemenin önemi somut bir şekilde gözlemlenmiştir. Proje, hedeflenen tüm isterleri karşılayacak şekilde tamamlanmıştır.

Projenin başlıca çıktıları şu şekilde özetlenebilir:

Teknik Bulgular:

5 regresyon algoritması karşılaştırılmış, **Random Forest $R^2=0.9356$** ile **açık ara en iyi sonucu vermiştir**. Bu sonuç, topluluk (ensemble) yöntemlerinin tek modellere kıyasla genellikle daha iyi genelleme yapabildiğini doğrulamaktadır.

Sınıflandırma görevinde **Decision Tree** ve **Random Forest %91.5 doğruluk oranına ulaşmıştır**. **SVM'nin zayıf performansı ($R^2 \approx 0$)**, bu algoritmanın büyük ölçekli veri setlerinde ön işleme ve hiperparametre ayarlaması gerektirdiğini ortaya koymuştur.

Pearson ve Spearman korelasyon analizleri, metrekarenin yat üzerinde en belirleyici faktör olduğunu (**$r \approx 0.78$**) teyit etmiştir.

Proje Çıktıları:

- 1.200 kayıtlık gerçek Türkiye emlak veri seti
- 5 regresyon + 4 sını andırma + 1 kümeleme algoritması
- 10+ analiz gra ği (Confusion Matrix, korelasyon heatmap, karşılaştırma gra kleri vb.)
- Streamlit tabanlı interaktif web arayüzü (5 sayfa)
- MATLAB versiyonu
- Teknik rapor (teorik açıklamalarla)

Saygılarımla,

Mehmet Çelik

Öğrenci No: 230007028

Yapay Zekaya Giriş - Dönem Sonu Projesi