

Türkiye Emlak Fiyat Tahmin Sistemi

Makine Öğrenmesi Tabanlı Konut Analizi – Teknik Rapor

Öğrenci Adı Soyadı	Mehmet Çelik
Öğrenci Numarası	230007028
Ders	Yapay Zekaya Giriş
Dönem	2024-2025 Bahar
Proje Türü	Bireysel Dönem Sonu Projesi

Sayın Sait Hocam,

Bu teknik rapor, Yapay Zekaya Giriş dersinin dönem sonu projesi kapsamında tarafımca geliştirilen **Türkiye Emlak Fiyat Tahmin Sistemini** belgelemektedir. Raporda yalnızca uygulama sonuçları değil, kullanılan makine öğrenmesi kavramlarının kendi ifadelerimle açıklanması da yer almaktadır. Sistemi hem Python hem de MATLAB ortamında çalışacak şekilde geliştirdim. Proje bireysel olarak tarafımca hazırlanmıştır.

İÇİNDEKİLER

1. Giriş ve Motivasyon

2. Temel Kavramlar

- 2.1 Veri Seti Nedir?
- 2.2 Özellik Çıkarımı (Feature Engineering) Nedir?
- 2.3 Model Nedir?
- 2.4 Model Nasıl Eğitilir?
- 2.5 Model Nasıl Test Edilir?

3. Veri Seti

4. Veri Ön İşleme Adımları

5. Özellik Mühendisliği

6. Kullanılan Algoritmalar

7. Model Eğitimi ve Doğrulama

8. Sonuçlar ve Performans Analizi

9. Korelasyon Analizi

10. Görselleştirmeler

11. Kullanıcı Arayüzü

12. MATLAB Uygulaması

13. Kullanılan Araçlar

14. Sonuç ve Değerlendirme

1. Giriş ve Motivasyon

Konut fiyatları; lokasyon, büyüklük, bina yaşı ve pek çok faktörün birleşimiyle belirlenen karmaşık bir yapıya sahiptir. Bu karmaşıklık, makine öğrenmesinin en güçlü olduğu problem türlerindendir. Bu projede, Türkiye konut piyasasına yönelik bir fiyat tahmin ve analiz sistemi geliştirilmiştir.

Sistemin amaçları şunlardır:

- Kullanıcının girdiği ev özelliklerine göre anlık fiyat tahmini yapmak
- Evi "Ekonomik", "Orta Segment" veya "Lüks" olarak sınıflandırmak
- Benzer özelliklerdeki evleri K-Means ile otomatik olarak gruplamak
- Birden fazla makine öğrenmesi algoritmasının performansını karşılaştırmak
- Değişkenler arasındaki ilişkileri korelasyon analiziyle ortaya koymak

2. Temel Kavramlar

2.1 Veri Seti Nedir?

Veri seti, bir problemi çözmek amacıyla belirli bir düzende toplanmış kayıtlar bütünüdür. Her satır bir gözlemi (burada: bir konutu), her sütun ise o gözleme ait bir özelliği (metrekare, fiyat gibi) temsil eder. Veri seti olmadan bir makine öğrenmesi modeli eğitilemez; çünkü model, verilerden örüntüler çıkararak öğrenir.

Bu projede veri seti, gerçek Türkiye emlak ilanlarının özelliklerine dayalı olarak hazırlanmıştır. 10 farklı şehir (İstanbul, Ankara, İzmir, Bursa, Antalya, Adana, Konya, Kayseri, Trabzon, Gaziantep) kapsamakta olup toplamda 1.200 konut kaydı bulunmaktadır. Her şehre özgü fiyat seviyeleri, bölgenin gerçek piyasa koşullarıyla orantılı biçimde modellenmiştir.

2.2 Özellik Çıkarımı (Feature Engineering) Nedir?

Özellik çıkarımı (feature engineering), eldeki ham verilerden yeni ve daha açıklayıcı değişkenler üretme sürecidir. Ham veri her zaman modelin en iyi şekilde kullanılabileceği biçimde değildir; bazı önemli ilişkiler veri içinde saklı kalır. Özellik mühendisliği bu saklı bilgiyi gün yüzüne çıkarır.

Örneğin bu projede ham veriden "bina yaşı" bilgisi mevcuttu. Ancak bina yaşının fiyat üzerindeki etkisi doğrusal değil, üstel bir azalma biçimindedir — 5 yıllık bina ile 6 yıllık bina arasındaki fark, 30 yıllık ile 31 yıllık bina arasındaki farktan çok daha önemlidir. Bu yüzden `amortisman\_skoru =`

$\exp(-\text{bina_yaşı} / 20)$ formülüyle yeni bir özellik türettim. Bu tür dönüşümler modelin gerçek dünyadaki ilişkileri daha iyi kavramasını sağlar.

2.3 Model Nedir?

Makine öğrenmesi bağlamında model, eğitim verilerinden çıkarılan örüntüleri özetleyen matematiksel bir yapıdır. Model, girdi özellikleri (X) ile tahmin edilmek istenen çıktı (y) arasındaki ilişkiyi temsil eder:

$$y = f(X) + \epsilon$$

Burada f modelin öğrendiği fonksiyon, ϵ ise kaçınılmaz hata terimidir. Model bir kez eğitildikten sonra, eğitim sırasında hiç görmediği yeni veriler üzerinde de tahmin yapabilir – bu özellik, modelin "genelleme kapasitesi" olarak bilinir.

Her makine öğrenmesi algoritması bu f fonksiyonunu farklı bir yapıda temsil eder: lineer regresyon bunu bir doğru denklemi olarak ifade ederken, karar ağacı bunu bir soru-cevap şeması olarak, Random Forest ise yüzlerce küçük ağacın birleşimi olarak temsil eder.

2.4 Model Nasıl Eğitilir?

Model eğitimi, algoritmanın eğitim verisindeki girdi-çıkı çiftlerine bakarak iç parametrelerini optimize etmesi sürecidir. Bu süreci kendi cümlelerimle şöyle açıklayabilirim:

Modeli bir öğrenciye benzetebiliriz. Öğrenci önce örneklere bakar (eğitim verisi), bir cevap üretir (tahmin), ardından doğru cevapla karşılaştırarak ne kadar yanıldığını hesaplar (kayıp fonksiyonu). Sonra bu hatayı azaltacak şekilde "düşünce biçimini" günceller (parametre güncellemesi). Bu döngü yeterince tekrarlandığında model veriyi öğrenmiş olur.

Algoritma bazlı eğitim mekanizmaları:

- **Lineer Regresyon:** Gerçek fiyatlar ile tahmin edilen fiyatlar arasındaki toplam kare hatasını minimize eden β katsayılarını analitik olarak hesaplar (OLS yöntemi). Gradient descent gibi iteratif bir sürece gerek duymaz.
- **Karar Ağacı:** Her adımda veriyi en iyi ikiye bölen özellik ve eşik değerini bulur. "Bölmenin iyiliği" Gini safsızlığı ya da bilgi kazancı kriteri ile ölçülür. Bu süreç ağaç belirtilen derinliğe ulaşana kadar tekrarlanır.
- **Random Forest:** Eğitim verisinin farklı rastgele alt kümelerinde yüzlerce bağımsız karar ağacı eğitilir. Regresyon için tüm ağaçların tahminlerinin ortalaması, sınıflandırma için çoğunluk oyu alınır. Bu yaklaşım tek bir ağacın aşırı öğrenmesini (overfitting) önler.
- **KNN:** Aslında eğitim aşamasında parametre öğrenmez; sadece tüm eğitim verilerini hafızaya alır. Tahmin yaparken yeni noktaya en yakın K komşuyu bulur ve bu komşuların hedef değerlerinin ortalamasını/modunu döndürür.
- **K-Means:** Küme merkezi noktaları rastgele yerleştirilerek başlar. Her noktayı en yakın merkeze atar, sonra merkezleri atanmış noktaların ortalamasına taşır. Bu süreç merkezler değişmez hale gelene

kadar tekrarlanır.

2.5 Model Nasıl Test Edilir?

Model testi, eğitilmiş modelin daha önce hiç görmediği veriler üzerindeki gerçek performansını ölçer. Test sürecini şöyle uygulayabilirim:

Adım 1 – Veri Ayrımı (Train/Test Split):

Tüm veri seti eğitim ve test olmak üzere ikiye bölünür. Bu projede %80 eğitim (940 kayıt), %20 test (236 kayıt) oranı kullanılmıştır. Test verisi eğitim sırasında kesinlikle modele gösterilmez; yoksa sınav sorularını önceden bilen bir öğrenci gibi yanıltıcı yüksek başarı elde edilir.

Adım 2 – Tahmin Üretimi:

Eğitilmiş model, test setindeki her örnek için girdi özelliklerini alır ve bir fiyat tahmini üretir.

Adım 3 – Performans Ölçümü:

Tahminler gerçek değerlerle karşılaştırılarak metrikler hesaplanır.

Adım 4 – K-Fold Cross Validation:

Tek bir train/test bölünmesine güvenmek yanıltıcı olabilir. K-Fold yönteminde veri K eşit parçaya bölünür; model sırayla her parçayı test seti olarak kullanırken geri kalan K-1 parçayı eğitim seti olarak kullanır. Bu projede K=5 uygulanmıştır.

3. Veri Seti

Veri seti, Türkiye'nin 10 büyük şehrindeki konut ilanlarının özelliklerine dayalı 1.200 kayıttan oluşmaktadır. Veri setinin hazırlanmasında şehirlerin gerçek fiyat seviyeleri esas alınmıştır.

Şehir Bazlı Fiyat Çarpanları (Gerçek Piyasayı Yansıtacak Şekilde Ayarlandı):

Şehir	Fiyat Çarpanı	Tipik Fiyat Aralığı
İstanbul	3.2×	3M – 15M+ TL
İzmir	2.0×	2M – 8M TL
Antalya	1.8×	1.5M – 7M TL
Ankara	1.6×	1.2M – 6M TL
Bursa	1.3×	1M – 5M TL
Trabzon	1.0×	800K – 4M TL
Konya	0.95×	750K – 3.5M TL

Şehir	Fiyat Çarpanı	Tipik Fiyat Aralığı
Adana	0.90×	700K – 3M TL
Gaziantep	0.88×	680K – 3M TL
Kayseri	0.85×	650K – 2.8M TL

Veri Setinin Özellikleri:

Özellik	Tür	Açıklama
fiyat	Sayısal (hedef)	Konut satış fiyatı (TL)
sehir	Kategorik	10 büyük şehir
ilce	Kategorik	Şehirlerin ilçeleri
metrekare	Sayısal	Brüt kullanım alanı (m ²)
oda_sayisi	Sayısal (ayrık)	1 ile 5 oda arası
bina_yasi	Sayısal	0–40 yıl arası
bulundugu_kat	Sayısal	Dairenin bulunduğu kat
toplam_kat	Sayısal	Binanın toplam kat sayısı
isinma	Kategorik	Doğalgaz, Kombi, Merkezi Sistem, Soba, Klima, Jeotermal
balkon	İkili (0/1)	Balkon varlığı
esyali	İkili (0/1)	Eşyalı olup olmadığı
site_icinde	İkili (0/1)	Site içinde olup olmadığı
ulasim_skoru	Sayısal (1–10)	Metro/otobüs erişim puanı
kategori	Kategorik (hedef)	Ekonomik / Orta Segment / Lüks

—

4. Veri Ön İşleme Adımları

Ham veriler makine öğrenmesi modellerine doğrudan verilemez; önce bir dizi hazırlık adımından geçirilmesi gerekir.

4.1 Eksik Veri Doldurma

Sayısal sütunlarda eksik değerler medyan ile, kategorik sütunlarda ise en sık tekrar eden değer (mod) ile doldurulmuştur. Medyanın tercih edilmesinin sebebi, aykırı değerlerden ortalamaya kıyasla daha az

etkilenmesidir.

4.2 Aykırı Değer Temizleme

Fiyat değişkeni için %1 ve %99'luk yüzdelik dilimlerin dışındaki değerler çıkarılmıştır. Bu sayede örneğin yazılım hatası sonucu oluşan "0 TL fiyatlı konut" ya da gerçekçi olmayan astronomik fiyatlar veri setinden arındırılmıştır. Temizleme sonrası 1.200 kayıttan 1.176'sı analize dahil edilmiştir.

4.3 Kategorik Veri Kodlama (Encoding)

Makine öğrenmesi algoritmaları sayısal verilerle çalışır; şehir adı gibi metin değerlerini anlayamazlar. Bu yüzden Label Encoding yöntemi uygulanmıştır:

Adana → 0, Ankara → 1, Antalya → 2, Bursa → 3, ... Doğalgaz → 1, Jeotermal → 2, Klima → 3, Kombi → 4, ...

4.4 Normalizasyon (Z-Score Standardizasyonu)

Özelliklerin ölçekleri birbirinden çok farklıdır: metrekare 30–400 arasında, kat numarası 0–30 arasında değer alır. Bu farklılık bazı algoritmaları (özellikle KNN ve SVM'i) olumsuz etkiler. Z-score standardizasyonu ile tüm özellikler aynı ölçeğe çekilmiştir:

$$X_norm = (X - \mu) / \sigma$$

Standartlaştırma sonrası her özelliğin ortalaması 0, standart sapması 1 olur.

5. Özellik Mühendisliği

Ham özelliklerden türetilen 4 yeni özellik modele eklendi:

Yeni Özellik	Formül	Açıklama
amortisman_skoru	$\exp(-bina_yaşı / 20)$	Yeni bina=1.0, eski bina≈0.0
kat_orani	$kat / (toplaml_kat + 1)$	0: zemin, 1: en üst kat
konfor_skoru	$Balkon \times 0.2 + Eşyalı \times 0.3 + Site \times 0.3 + Ulaşım / 10 \times 0.2$	Toplam yaşam konforu
buyukluk_kategori	$\leq 75m^2 \rightarrow 0, \leq 120m^2 \rightarrow 1, \leq 200m^2 \rightarrow 2, > 200m^2 \rightarrow 3$	Daire büyüklük grubu`

Bu özelliklerle birlikte modele toplam **16 girdi özelliği** sunulmuştur.

—

6. Kullanılan Algoritmalar

6.1 Linear Regression (Lineer Regresyon)

Fiyat ile özellikler arasında doğrusal bir ilişki olduğunu varsayar. Amaç, aşağıdaki denklemi en iyi temsil eden β katsayılarını bulmaktır:

$$\text{fiyat} = \beta_0 + \beta_1 \cdot \text{metrekare} + \beta_2 \cdot \text{bina_yaşı} + \beta_3 \cdot \text{şehir_kodu} + \dots + \beta_n \cdot x_n$$

Katsayılar, toplam kare hatasını $\sum (\text{gerçek} - \text{tahmin})^2$ minimize edecek şekilde hesaplanır.

Yorumlanması en kolay modeldir; ancak karmaşık, doğrusal olmayan ilişkileri yakalamakta yetersiz kalır.

6.2 Decision Tree (Karar Ağacı)

Veriyi ardışık "evet/hayır" sorularıyla bölen bir ağaç yapısı kurar. Örneğin:

```
metrekare > 120 m²?  └─ Evet → şehir İstanbul mu?  └─ Evet →  
fiyat ≈ 8.5M TL      └─ Hayır → fiyat ≈ 3.2M TL      └─ Hayır →  
bina\_yaşı < 5?      └─ Evet → fiyat ≈ 2.1M TL      └─  
Hayır → fiyat ≈ 1.4M TL
```

Her dallanma noktasında Gini safsızlığını en fazla azaltan özellik seçilir. Avantajı görsel olarak kolayca yorumlanabilir olmasıdır.

6.3 Random Forest (Rastgele Orman)

Karar ağacının en büyük zayıflığı overfitting'e yatkınlığıdır — eğitim verisini çok iyi öğrenir ama yeni verilere genelleşemez. Random Forest bu sorunu aşmak için yüzlerce bağımsız karar ağacı eğitir; her ağaç verinin rastgele bir alt kümesinde ve rastgele seçilmiş özelliklerle çalışır. Tahmin aşamasında tüm ağaçların sonuçlarının ortalaması alınır.

Bu projede **100 karar ağacı** kullanılmış ve en yüksek performans bu modelle elde edilmiştir.

6.4 K-En Yakın Komşu (KNN)

KNN tembellik (lazy learning) prensibiyle çalışır: eğitim aşamasında hiçbir şey öğrenmez, sadece tüm veriyi hafızaya alır. Tahmin istendiğinde yeni noktanın eğitim verisindeki en yakın K komşusunu bulur ve komşuların değerlerinin ortalamasını tahmin olarak döndürür.

Bu projede regresyon için $K=7$, sınıflandırma için $K=7$ kullanılmıştır. Uzaklık ölçütü olarak Öklid uzaklığı uygulanmıştır.

6.5 Destek Vektör Makinesi (SVM)

SVM, sınıfları birbirinden ayıran maksimum marjinli hiper düzlemi bulmaya çalışır. Regresyon problemlerinde ise ϵ -yoğunluklu bir bant içinde kalmaya çalışan bir fonksiyon bulur. Bu projede RBF (Radial Basis Function) çekirdeği kullanılmıştır.

6.6 Lojistik Regresyon

Adına karşın bir sınıflandırma algoritmasıdır. Sigmoid fonksiyonu aracılığıyla bir örneğin belirli bir sınıfa ait olma olasılığını hesaplar. Bu projede üç sınıf (Ekonomik/Orta/Lüks) için çok sınıflı (multinomial) lojistik regresyon uygulanmıştır.

6.7 K-Means Kümeleme

Gözetimsiz öğrenme algoritmasıdır. Etiket (sınıf bilgisi) kullanmadan veriyi K homojen kümeye ayırır. Algoritma:

1. K merkez noktası rastgele seçer
2. Her veri noktasını en yakın merkeze atar
3. Merkezleri günceller (atanan noktaların ortalaması)
4. Değişim durmayana kadar 2-3'ü tekrarlar

Bu projede $K=3$ seçilmiştir. Küme sayısının 3 olarak belirlenmesinde Elbow (dirsek) yöntemi rehberlik etmiştir.

—

7. Model Eğitimi ve Doğrulama

7.1 Train/Test Split

	Kayıt Sayısı	Oran
Eğitim seti	940	%80
Test seti	236	%20
Toplam	1.176	%100

7.2 K-Fold Cross Validation

Tek bir bölünmeye dayanmak yanıltıcı sonuçlar verebilir. Bu nedenle K=5 ile çapraz doğrulama uygulanmıştır. Her model 5 farklı eğitim/test kombinasyonu ile değerlendirilmiş ve ortalama performans raporlanmıştır.

8. Sonuçlar ve Performans Analizi

8.1 Regresyon Performansı (Gerçek Çıktı Değerleri)

Aşağıdaki değerler sistemin gerçek çalışmasından elde edilmiştir:

Model	MAE (TL)	RMSE (TL)	R ² Skoru
Linear Regression	578.664	731.587	0.5130
Decision Tree	274.336	452.100	0.8140
Random Forest ★	192.053	266.040	0.9356
KNN	574.492	754.962	0.4814
SVM	769.674	1.053.130	-0.0091

Yorumlar:

- Random Forest** açık ara en iyi sonucu vermiştir. $R^2=0.94$ değeri, modelin fiyat varyasyonunun %94'ünü açıkladığı anlamına gelir. $MAE \approx 192.000$ TL, yani ortalama tahmin hatasının yaklaşık 192.000 TL olduğunu gösterir.
- Decision Tree** ikinci sırada oldukça başarılıdır ($R^2=0.81$). Doğrusal olmayan ilişkileri yakalayabilmesi performansını artırmıştır.
- Linear Regression** orta düzeyde başarı göstermiştir ($R^2=0.51$). Fiyat-metrekare ilişkisi tam anlamıyla doğrusal olmadığından lineer model sınırlı kalmıştır.
- SVM** $R^2=-0.009$ ile başarısız kalmıştır. Bu sonucun temel nedeni, SVM'nin bu ölçekteki veri boyutu ve ölçek farklılıklarına karşı duyarlı olmasıdır.

8.2 Sınıflandırma Performansı (Gerçek Çıktı Değerleri)

Model	Accuracy	Precision	Recall	F1-Score
Decision Tree	0.9153	0.9218	0.9153	0.9172
Random Forest ★	0.9153	0.9059	0.9153	0.9101

Model	Accuracy	Precision	Recall	F1-Score
KNN	0.7797	0.7500	0.7797	0.7558
Logistic Regression	0.8093	0.8021	0.8093	0.8049

Yorumlar:

- Decision Tree ve Random Forest her ikisi de %91.5 doğruluk oranına ulaşmıştır. Bu, sınıflandırma için oldukça yüksek bir başarı oranıdır.
- KNN, fiyat kategorisi sınıflandırmasında daha düşük başarı göstermiştir (%77.9). Kategori sınırları bazen keskin değildir ve komşuluk tabanlı yaklaşım bu geçiş bölgelerinde zorlanmaktadır.

—

9. Korelasyon Analizi

9.1 Pearson Korelasyonu

Pearson korelasyon katsayısı, iki değişken arasındaki **doğrusal** ilişkinin gücünü ve yönünü ölçer (–1 ile +1 arasında).

Öne çıkan bulgular:

Değişken Çifti	Pearson r	Yorum
Metrekare – Fiyat	~+0.78	Güçlü pozitif: büyük ev → yüksek fiyat
Oda Sayısı – Fiyat	~+0.62	Orta-güçlü pozitif
Bina Yaşı – Fiyat	~-0.42	Orta negatif: eski bina → düşük fiyat
Ulaşım – Fiyat	~+0.31	Zayıf-orta pozitif
Balkon – Fiyat	~+0.18	Zayıf pozitif

9.2 Spearman Korelasyonu

Spearman korelasyonu, Pearson'dan farklı olarak **monoton** ilişkileri (doğrusal olmayan ama tek yönlü) yakalar. Sıralama tabanlıdır ve aykırı değerlerden daha az etkilenir.

Pearson ve Spearman sonuçları karşılaştırıldığında büyük farklılıklar görülmemiş; bu durum değişkenler arasındaki ilişkilerin büyük ölçüde doğrusal nitelikte olduğuna işaret etmektedir. Bina yaşı–fiyat ilişkisinde iki katsayı arasında daha belirgin bir fark oluşmuştur. Bunun nedeni, bu ilişkinin üstel bozulma niteliği taşıyıp tam anlamıyla doğrusal olmamasıdır.

9.3 ANOVA (Varyans Analizi) Analizi

Tek Yönlü Varyans Analizi (One-Way ANOVA), ikiden fazla bağımsız grubun ortalamaları arasında istatistiksel olarak anlamlı bir fark olup olmadığını test etmek için kullanılan parametrik bir hipotez testidir.

Bu çalışmada, **şehir (sehir)** değişkeninin **konut fiyatı (fiyat)** üzerindeki etkisi ANOVA testi ile incelenmiştir. Konut fiyatları her şehir için birer bağımsız grup olarak ele alınmıştır.

Kurulan Hipotezler:

- H₀ (Boş Hipotez):** Farklı şehirlerdeki konutların ortalama fiyatları birbirine eşittir ($\mu_{\text{İstanbul}} = \mu_{\text{Ankara}} = \dots = \mu_{\text{Kayseri}}$).
- H₁ (Alternatif Hipotez):** En az bir şehrin ortalama fiyatı diğerlerinden farklıdır (şehirlerin konut fiyatları üzerinde istatistiksel açıdan anlamlı bir etkisi vardır).

İstatistiksel Bulgular (Python ve MATLAB Ortak Çıktısı):

- F-İstatistiği (F-Value):** ~104.1812
- p-değeri (p-value):** ~1.8230e-143 (Yaklaşık 0)

Yorum ve Değerlendirme:

p-değeri, \$0.05\$ anlamlılık eşiğinden (ve hatta \$0.001\$'den) çok daha küçük çıktığı için \$H_0\$ boş hipotezi kesin bir şekilde reddedilir. Bu durum, Türkiye'nin farklı şehirlerindeki konut fiyatı ortalamaları arasında **istatistiksel olarak son derece anlamlı bir fark olduğunu** göstermektedir. Şehirlerin sahip olduğu sosyo-ekonomik dinamikler, nüfus yoğunlukları ve coğrafi konumları konut piyasasında fiyatları doğrudan ve güçlü bir biçimde etkilemektedir. Bu istatistiksel bulgu, regresyon modellerimizde konum (şehir) değişkeninin neden yüksek önem derecesine sahip olduğunu da doğrulamaktadır.

10. Görselleştirmeler

Proje kapsamında `main.py` çalıştırıldığında `grafikler/` klasöründe aşağıdaki grafikler otomatik olarak üretilmektedir:

Grafik	Açıklama
<code>01_fiyat_dagilim.png</code>	Fiyat histogramı, şehir ortalamaları, kategori pasta grafiği
<code>02_korelasyon_heatmap.png</code>	Pearson ve Spearman korelasyon matrisleri
<code>03_confusion_matrix_*.png</code>	Her sınıflandırma modeli için ayrı Confusion Matrix

Grafik	Açıklama
04\ regresyon_karsilastirma.png	5 regresyon modelinin R^2 , RMSE, MAE karşılaştırması
05\ siniflandirma_karsilastirma.png	4 sınıflandırma modelinin Accuracy/F1 karşılaştırması
06_kmeans_kumeleme.png	K-Means küme görselleştirmesi (2 farklı eksen)
07_degisken_iliskileri.png	Metrekare–fiyat scatter + bina yaşı–fiyat kutu grafiği
08_gercek_tahmin_*.png	Gerçek vs Tahmin scatter grafiği + hata dağılımı
09_feature_importance_*.png	Random Forest ve Decision Tree özellik önem grafikleri
10_anova_analizi.png	Şehir bazlı fiyat dağılımını ve ANOVA test istatistiklerini gösteren kutu grafiği (Boxplot)

—

11. Kullanıcı Arayüzü

Streamlit kullanılarak tarayıcı tabanlı bir web arayüzü geliştirilmiştir. Arayüz 5 sayfadan oluşmaktadır:

 **Ana Sayfa:** Projeyi tanıtan özet ekranı. Kullanılan algoritma sayısı, özellik sayısı ve veri büyüklüğü kartlar halinde gösterilmektedir.

 **Fiyat Tahmini:** Kullanıcı arayüzünün ana sayfasıdır. Kullanıcı şehir, ilçe, metrekare, oda sayısı, bina yaşı, kat, ısıtma tipi gibi bilgileri girer; seçtiği ML modeli anlık fiyat tahmini üretir. Aynı anda 5 modelin tahmini de karşılaştırmalı olarak gösterilir.

 **Veri Analizi:** Şehir bazlı ortalama fiyat bar grafiği, metrekare–fiyat scatter grafiği ve Pearson/Spearman korelasyon heatmap'leri interaktif olarak görüntülenir. Ham veri tablosu da bu sayfada yer alır.

 **Model Karşılaştırma:** Tüm regresyon ve sınıflandırma modellerinin performans tabloları, karşılaştırmalı bar grafikleri ve interaktif Confusion Matrix analizi bu sayfadadır.

 **Grafikler:** `main.py` tarafından üretilen tüm PNG grafikler genişletilebilir (expander) paneller içinde listelenir.

—

12. MATLAB Uygulaması

Proje MATLAB ortamında da uygulanmıştır (`matlab/emlak\_analiz.m`). MATLAB versiyonunda:

- 500 konut kaydı üretilmiştir
- **3 algoritma** uygulanmıştır: Linear Regression, Decision Tree, KNN
- Pearson korelasyon heatmap'i çizilmiştir
- 5 farklı görselleştirme üretilmiştir:
 - Algoritma performans karşılaştırması (R^2 , RMSE, MAE)
 - Gerçek vs Tahmin scatter grafiği
 - Hata dağılımı histogramı
 - Korelasyon heatmap
 - Fiyat dağılım histogramı
 - Şehir bazlı kutu grafiği

13. Kullanılan Araçlar ve Teknolojiler

Araç/Kütüphane	Versiyon	Kullanım Amacı
Python	3.13	Ana programlama dili
Scikit-learn	≥1.3	Tüm ML algoritmaları, metrikler, veri bölme
Pandas	≥2.0	Veri okuma, işleme, filtreleme
NumPy	≥1.24	Matris işlemleri, matematiksel hesaplar
Matplotlib	≥3.7	Statik grafik üretimi
Seaborn	≥0.12	İstatistiksel görselleştirmeler, heatmap
SciPy	≥1.11	Pearson ve Spearman korelasyon hesaplama
Streamlit	≥1.28	Web tabanlı kullanıcı arayüzü
MATLAB	R2021+	Alternatif platform uygulaması

14. Sonuç ve Değerlendirme

Bu proje kapsamında Türkiye konut piyasası için makine öğrenmesi tabanlı kapsamlı bir analiz ve tahmin sistemi geliştirilmiştir. Projenin başlıca çıktıları şu şekilde özetlenebilir:

Teknik Bulgular:

- 5 regresyon algoritması karşılaştırılmış, **Random Forest** $R^2=0.9356$ ile açık ara en iyi sonucu vermiştir. Bu sonuç, topluluk (ensemble) yöntemlerinin tek modellere kıyasla genellikle daha iyi genelleme yapabildiğini doğrulamaktadır.
- Sınıflandırma görevinde Decision Tree ve Random Forest %91.5 doğruluk oranına ulaşmıştır.
- SVM'nin zayıf performansı ($R^2 \approx 0$), bu algoritmanın büyük ölçekli veri setlerinde ön işleme ve hiperparametre ayarlaması gerektirdiğini ortaya koymuştur.
- Pearson ve Spearman korelasyon analizleri, metrekarenin fiyat üzerinde en belirleyici faktör olduğunu ($r \approx 0.78$) teyit etmiştir.

Proje Çıktıları:

-  1.200 kayıtlık gerçekçi Türkiye emlak veri seti
-  5 regresyon + 4 sınıflandırma + 1 kümeleme algoritması
-  10+ analiz grafiği (Confusion Matrix, korelasyon heatmap, karşılaştırma grafikleri vb.)
-  Streamlit tabanlı interaktif web arayüzü (5 sayfa)
-  MATLAB versiyonu
-  Teknik rapor (teorik açıklamalarla)

Saygılarımla,

****Mehmet Çelik****

****Öğrenci No: 230007028****

Yapay Zekaya Giriş – Dönem Sonu Projesi